1. Estrutura do Plano de Execução

1.1. Definição do Problema e Objetivos

- **Descrição do problema:** O sistema educacional enfrenta o desafio de manter a presença e o comparecimento regular dos estudantes nas escolas. Este projeto busca investigar como a infraestrutura das escolas influencia o comparecimento/frequência dos alunos, utilizando dados públicos do Ministério da Educação (MEC) e do INEP (Censo Escolar).
- **Objetivos do projeto:** O principal objetivo é investigar a correlação entre a infraestrutura escolar e as taxas de presença/frequência dos alunos nas escolas, identificando os fatores mais determinantes que influenciam esse aspecto. Além disso, o projeto visa criar um modelo preditivo que possa ser usado para orientar políticas públicas de investimento em infraestrutura escolar para maximizar o comparecimento dos alunos e fazer com que, ao se planejar uma reforma, seja possível saber quais são os melhores itens de infraestrutura para investir que trarão o maior retorno em termos de frequência dos estudantes.
- **Métricas de sucesso:**

  Usaremos a métrica de Acurácia e nosso objetivo é ter > 75%:

  - **Accuracy (Acurácia):** mede a proporção de previsões corretas em relação ao total. Usado em classificação.

- **Stakeholders:** Os principais stakeholders incluem:
  - Ministério da Educação (MEC): Interesse em entender a relação entre infraestrutura e a presença dos alunos para ajustar políticas públicas.
  - Secretarias de Educação estaduais e municipais: Responsáveis pela implementação de melhorias na infraestrutura escolar.
  - Educadores e gestores escolares: Interessados nas recomendações práticas para a melhoria do ambiente escolar.
  - Alunos e suas famílias: Beneficiários diretos de melhorias na infraestrutura escolar e maior acesso ao ensino superior.
  - Pesquisadores acadêmicos: Envolvidos na análise e disseminação dos resultados.

1.2. Escopo e Requisitos

- **Fontes de dados:**
    - **Censo Escolar 2024:** Dados atualizados sobre a infraestrutura das escolas no Brasil, acessíveis no portal de dados abertos do INEP. Esse conjunto de dados inclui informações sobre a infraestrutura física das escolas, como acessibilidade, recursos educacionais disponíveis (como internet, laboratórios, etc.) e outros aspectos relacionados ao ambiente escolar.

- **Limitações conhecidas:**
    - **Dados incompletos ou desatualizados:** Apesar de usar o dataset mais recente do Censo Escolar (2024), podem existir lacunas nos dados, como escolas que não têm informações completas sobre sua infraestrutura ou faltam dados.
    - **Fatores externos:** Outros fatores, como políticas educacionais locais e diferenças nas práticas de ensino, podem influenciar os resultados do ENEM, além da infraestrutura escolar.
    - **Escalabilidade:** O projeto pode enfrentar dificuldades ao lidar com grandes volumes de dados de diversas fontes (ENEM, Censo Escolar, dados regionais) se a infraestrutura de processamento não for suficiente.

- **Requisitos técnicos:**
    - **Ferramenta:**
        - Python (bibliotecas como pandas, numpy, matplotlib e seaborn) para análise de dados, manipulação e visualizações.
        - Jupyter Notebooks desenvolvimento de análises exploratórias e criação de relatórios interativos.

- **Habilidades necessárias:**
    - **Análise de dados:** Manipulação de grandes volumes de dados, identificação de padrões e correlações.
    - **Estatística:** Para análise de correlação entre infraestrutura escolar e desempenho no ENEM.

    - **Machine Learning:** Para treinar e usar modelos preditivos para entender o impacto de diferentes variáveis de infraestrutura.
    - **Comunicação de dados:** Habilidade para traduzir os resultados da análise em recomendações políticas claras e baseadas em dados.
    - **Gestão de dados:** Uso de ferramentas de ETL para integrar dados de diferentes fontes e prepará-los para análise.

- **Entregáveis:**
    - **Jupyter Notebook:** Um notebook contendo todo o processo de pesquisa, análise exploratória, pré-processamento, modelagem e avaliação para o treinamento do modelo.
    - **Apresentação:** Apresentação em sala de aula sobre os resultados finais do projeto.

1.3. Etapas do Projeto

1. **Entendimento do Negócio**
    - Pesquisa em artigos, relatórios do MEC/INEP e literatura acadêmica
    - Definição clara do problema e objetivos
    - Estabelecimento das métricas de sucesso (técnicas e de negócio)

2. **Entendimento dos Dados**
    - Coleta dos microdados do ENEM 2024 e do Censo Escolar 2024
    - Estudo do dicionário de variáveis e metadados
    - Análise estatística descritiva inicial (abstenção e desempenho por região)
    - Identificação de inconsistências e lacunas nos dados

3. **Preparação dos Dados**
    - Limpeza e padronização de variáveis
    - Tratamento de valores ausentes e codificação de categorias
    - Criação de novas features.
    - Divisão dos dados em treino, validação e teste

4. **Modelagem**
    - Seleção dos algoritmos candidatos (classificação e regressão)
    - Treinamento inicial (baseline)
    - Comparação de desempenho com métricas técnicas (AUC, recall, R^2)
    - Otimização de hiperparâmetros e refinamento do modelo final

5. **Avaliação**
    - Validação do modelo final com métricas de negócio
    - Comparação dos resultados com hipóteses de pesquisa

6. **Implantação**
    - Preparação da apresentação final
    - Entrega do notebook consolidado

1.4. Cronograma e Marcos

Cronograma

- **Sprint 2 (14/10)**: **Pré-processamento completo**
    - Finalização do pré-processamento dos dados, incluindo limpeza, tratamento de valores ausentes e preparação para a modelagem.

- **Sprint 3 (28/10)**: **Modelagem inicial e estudo de feature engeering**
    - Implementação e avaliação de modelos iniciais utilizando os dados pré-processados, com testes de diferentes algoritmos de machine learning e o início do estudo de feature feature engineering.

- **Sprint 4 (06/11)**: **Otimização e refinamento**
    - Avaliação de novas features, organização de todos os artefatos do projeto e salvar os modelos treinados.

- **Sprint 5 (25/11)**: **Finalização e preparação da apresentação**
    - Consolidação dos resultados finais, ajustes nos modelos, preparação de um relatório final e criação de uma apresentação.

Marcos

- **25/09: Planejamento e setup inicial**
    - Definição do escopo, objetivos e cronograma do projeto. Configuração de ambiente de trabalho, ferramentas e coleta inicial de dados.

- **02/10: Entrega do Plano de Execução**
    - Entrega do documento do plano de execução, detalhando as etapas e cronograma do projeto, incluindo objetivos e recursos necessários.

- **12/10: Aprovação do pré-processamento e análise exploratória**
    - Revisão e aprovação do processo de limpeza dos dados e análise exploratória inicial realizada.

- **21/10: Conclusão da modelagem inicial**

    - Conclusão dos primeiros testes de modelagem e análise dos resultados preliminares, incluindo avaliação de desempenho dos modelos.

- **02/11: Revisão dos resultados de otimização**
    - Reunião para revisar o desempenho dos modelos otimizados e fazer ajustes finais antes da entrega.

- **25/11: Consolidação do notebook e correções finais**
    - Unificar o notebook em um único arquivo e realizar os ajustes finais necessários no modelo.

- **29/11: Criação de roteiro e slides**
    - Reunião para a criação do roteiro para a apresentação e dos slides

- **02/12: Apresentação final**
    - Apresentar o trabalho realizado ao longo do semestre

1.5. Riscos e Mitigações

Risco	**Probabilidade**	**Impacto**	**Mitigação**	**Plano de contingência**
Qualidade de dados insuficiente	Baixa	Alto	Realizar avaliação inicial dos dados, planejar esforço para limpeza e engenharia de features	Caso os dados continuem insuficientes, buscar fontes alternativas ou complementar com dados externos
Desempenho do modelo abaixo do esperado	Média	Alto	Testar múltiplos algoritmos e investir na criação de feature engineering	Ajustar hiperparâmetros e explorar diferentes técnicas de modelagem, como ensembles ou tuning adicional
Inconsistências ou lacunas nos dados	Baixa	Médio	Validação inicial dos dados, tratamento de valores ausentes e padronização	Se lacunas significativas forem encontradas, buscar dados adicionais ou ajustar o escopo do projeto
Falta de alinhamento entre infraestrutura escolar e variáveis de impacto	Média	Alto	Refinar as variáveis relacionadas à infraestrutura e fazer análises qualitativas detalhadas	Ajustar a análise de forma iterativa, envolvendo mais dados qualitativos ou especialistas de campo para redefinir as variáveis
Restrições legais e privacidade de dados	Baixa	Alto	Garantir que os dados utilizados estejam em conformidade com a LGPD, usando dados públicos ou anonimizados	Caso haja problemas legais, interromper o uso de dados sensíveis e buscar alternativas como dados anonimizados ou agregados

Limitações de tempo para análise e entrega de resultados	Baixa	Alto	Estabelecer um cronograma realista, com marcos e entregáveis bem definidos	Revisar o cronograma e focar nas tarefas prioritárias, ajustando o escopo se necessário para garantir a entrega dos resultados principais
Limitações de memória e processamento no Google Colab	Média	Alto	Otimizar os algoritmos e reduzir o uso de memória com técnicas de amostragem ou paralelização no processamento	Caso o Colab não consiga lidar com o volume de dados, dividir o dataset em partes menores ou rodar o projeto localmente em nossas máquinas
Falhas de conectividade e perda de dados no Google Colab	Média	Alto	Salvar os dados e modelos periodicamente no Google Drive ou outra solução de backup	Caso a sessão seja desconectada ou o ambiente de Colab perca os dados, restaurar a partir do backup mais recente e retomar a execução

1.6. Governança e Comunicação

- **Papéis e responsabilidades:** Cada membro do grupo terá responsabilidades específicas no projeto, conforme detalhado abaixo:
  Nome: José Carlos Neto
  Responsabilidades: Visualization, Research

  Nome: Guilherme Cunha
  Responsabilidades: Data Engineering, ML Modeling

  Nome: Luidgi Colimerio
  Responsabilidades: ML Modeling, Research

  Nome: Lucio Oliveira
  Responsabilidades: Documentation, Visualization

  Nome: Rafael Estevao
  Responsabilidades: Data Engineering, Documentation

- **Processo de tomada de decisão:**
  - As decisões serão tomadas após reuniões realizadas presencialmente ou pelo Discord semanalmente. Durante essas reuniões, os membros discutirão as questões técnicas e estratégicas do projeto, levando em consideração as contribuições de todos. O líder da reunião (rotativo) será responsável por garantir que as discussões sejam concluídas com consenso ou, quando necessário, por meio de votação.
- **Frequência de comunicação:**
  - Reuniões semanais: As reuniões serão realizadas semanalmente, seja presencialmente ou pelo Discord, para discutir o andamento do projeto, alinhar ações e tomar decisões.
  - Relatórios de progresso: Relatórios de progresso serão feitos semanalmente no notebook disponibilizado para o controle da sprint, assim ficando mais fácil de fazer o controle desse artefato.

    - Atualizações informais: Atualizações rápidas podem ser feitas de forma mais frequente no grupo de WhatsApp, conforme necessário para garantir que todos os membros do projeto estejam alinhados.
- **Canais de comunicação:**
    - O grupo de WhatsApp será o canal de comunicação principal para troca de mensagens rápidas, atualizações e discussão de pontos pontuais. O Discord será utilizado para reuniões semanais de alinhamento e discussões mais profundas. O e-mail será usado para o envio de documentos formais e informações mais detalhadas ou quando for necessário compartilhar materiais com maior complexidade (ex.: relatórios ou entregáveis).